

修士論文

# Adaptive PolyDice Loss with Uncertainty-Based Difficulty Estimation for Medical Image Segmentation

M243422 廣池 友哉

指導教員 古居 彬 准教授

令和 8 年 2 月 3 日

広島大学 大学院先進理工系科学研究科  
情報科学プログラム



# 目次

1	はじめに	2
2	予備知識	4
2.1	PolyDice Loss . . . . .	4
2.2	MC Dropout . . . . .	7
3	提案法	9
3.1	概要 . . . . .	9
3.2	不確実性に基づく画像難易度の定量化 . . . . .	11
3.3	適応的損失形状制御 . . . . .	14
4	実験	19
4.1	実験設定 . . . . .	19
4.2	結果と議論 . . . . .	23
5	結論	36
	謝辞	37
	参考文献	38

# 1 はじめに

医用画像セグメンテーションは、診断支援や治療計画において不可欠な技術であり、正常組織または異常組織の領域を抽出することが求められる。特に大腸ポリープ [1] や頭頸部がん放射線治療における危険臓器 [2] の検出など、臨床応用が進んでいる。

しかしながら、医用画像セグメンテーションには固有の課題が存在する。特に重要な問題として、クラス不均衡が挙げられる。医用画像では背景領域が大部分を占め、対象となる病変は相対的に小さい領域しか占めないことが多い。この状況下では、従来の分類タスクで広く使われている Cross-Entropy Loss [3] は背景領域の学習に偏り、臨床的に重要な小病変や曖昧な境界部分の正確なセグメンテーションが困難となる。

この課題に対処するため、クラス不均衡に対して頑健な Dice Loss [4] やその多くの拡張手法が提案され、CT 画像 [5, 6] や MRI 画像 [7] において高い性能が報告されている。しかし、これらの損失関数は全画像に対して固定的な形状を持つという制約がある。医用画像は、撮影条件や個体差に加え、病変サイズ・形状の著しいばらつき、組織間のコントラストの違い、あるいは境界の不明瞭さなどといった大きな多様性を有しており、画像ごとにセグメンテーションの難易度が大きく異なる。固定的な損失関数を用いると、容易な画像と困難な画像に対して同一の学習信号を与えるため、困難な画像に対する学習が不十分となる可能性がある。したがって、画像ごとの難易度に応じて損失関数を適応的に調整するアプローチが有望である。このような適応的学習の実現には、2つの要素が求められる。1つは、難易度の高い画像に対して学習信号を強化できるよう、損失関数の形状を柔軟に制御する手法である。もう1つは、各画像がモデルにとってどの程度困難であるかを学習中に評価するための難易度指標である。

本研究では、これら2つの要素を統合した適応的学習フレームワークを提案する。損失関数の形状制御には、Dice Loss を多項式展開して得られる PolyDice Loss [8] を用いる。PolyDice Loss は画像毎に最適なパラメータを用いて損失関数の形状を連続的に制御できるため、適応的学習に適している。難易度の定量化には、Monte Carlo

Dropout [9] (以下, MC Dropout) による不確実性推定を用いる. MC Dropout は, 推論時に Dropout を有効にすることで, モデルの認識的不確実性を効率的に推定できる. この不確実性は, モデルがその画像のセグメンテーションにおいてどの程度の確信を持てないかを反映しており, セグメンテーション難易度の指標として利用可能である. 提案手法では, 推定された不確実性指標に基づき PolyDice Loss の形状パラメータを動的に制御し, モデルが現時点で確信を持っていない画像には急峻な勾配を, 既に安定した予測が可能な画像には緩やかな勾配を与えることで, 効率的かつ頑健な学習の実現を目指す.

本研究の主要な貢献は以下の通りである.

1. **不確実性に基づく画像難易度の動的定量化手法の導入**: MC Dropout を用いて推論時の認識的不確実性を推定し, これを画像単位の「学習難易度」として定量化する手法を提案する. これにより, 医用画像の多様なセグメンテーション難易度を, モデル自身の確信度に基づいて客観的に評価することを可能にする.
2. **難易度に応じた損失関数の適応的制御フレームワークの構築**: 定量化された難易度指標に基づき, PolyDice Loss の形状パラメータを適応的に制御する学習フレームワークを構築した. 提案法は, 学習の進行に伴い変化する難易度に応じて損失関数の勾配を自動調整することで, 困難な症例への学習の注力と, 容易な症例による勾配支配の抑制を同時に実現する.
3. **複数のデータセットを用いた有効性と汎用性の実証**: 医用画像データセットを用いた比較実験により, 提案手法の有効性を検証した. 実験の結果, 従来の形状が固定された損失関数と比較してセグメンテーション精度が向上することを示した.

## 2 予備知識

### 2.1 PolyDice Loss

医用画像セグメンテーションで広く使用される Dice Loss は、クラス不均衡に頑健であるが、全画像に対して固定的な形状を持つという制約がある。本研究では、Dice Loss を多項式展開により拡張した PolyDice Loss [8]、特にその実用的な形式である PolyDice-1 Loss を採用する。PolyDice-1 Loss は、単一のパラメータ  $\epsilon$  で損失関数の形状を制御でき、画像の難易度に応じて勾配の急峻さを調整することが可能となる。

#### 2.1.1 Dice Loss の定義

画像サイズを  $H \times W$  とし、ピクセル位置を  $(i, j)$  で表す ( $i \in \{1, \dots, H\}, j \in \{1, \dots, W\}$ )。セグメンテーションタスクにおいて、モデルの予測確率マップを  $\hat{\mathbf{Y}} = \{\hat{y}_{i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$ 、その画像に対する正解マスクを  $\mathbf{Y} = \{y_{i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$  とすると、Dice Loss は次式で定義される。

$$\mathcal{L}_{\text{Dice}}(\hat{\mathbf{Y}}, \mathbf{Y}) = 1 - \frac{2 \sum_{j=1}^W \sum_{i=1}^H \hat{y}_{i,j} y_{i,j}}{\sum_{j=1}^W \sum_{i=1}^H (\hat{y}_{i,j}^2 + y_{i,j}^2)} \quad (1)$$

#### 2.1.2 幾何学的解釈と多項式展開

予測確率マップ  $\hat{\mathbf{Y}}$  と正解マスク  $\mathbf{Y}$  をそれぞれ長さ  $HW$  のベクトル  $\hat{\mathbf{y}}, \mathbf{y}$  として平坦化すると、Dice Loss は以下のように分解できる。

$$\mathcal{L}_{\text{Dice}} = 1 - s \cos \theta \quad (2)$$

ここで、 $s = \frac{2\langle \hat{\mathbf{y}}, \mathbf{y} \rangle}{\|\hat{\mathbf{y}}\|^2 + \|\mathbf{y}\|^2}$  はスケール成分、 $\theta = \arccos \frac{\langle \hat{\mathbf{y}}, \mathbf{y} \rangle}{\|\hat{\mathbf{y}}\| \|\mathbf{y}\|}$  は2つのベクトル間の角度を表す。この分解により、Dice Loss はスケール成分  $s$  と  $\cos \theta$  の積として理解できる。

方向成分  $\cos \theta$  に対して Taylor 展開を適用することで、PolyDice Loss の多項式表

現を導出する．学習が進むにつれて予測  $\hat{\mathbf{y}}$  は正解  $\mathbf{y}$  に近づくため，両ベクトルのなす角  $\theta$  は 0 に近づく．この性質を利用し， $\cos \theta$  を  $\theta = 0$  まわりでテイラー展開すると以下のように近似できる．

$$\cos \theta = 1 - \frac{\theta^2}{2!} + \frac{\theta^4}{4!} - \cdots \quad (3)$$

これを Dice Loss に代入し，整理すると PolyDice の一般形が得られる：

$$\mathcal{L}_{\text{PolyDice}} = 1 - s \left( 1 - \frac{\theta^2}{2!} + \frac{\theta^4}{4!} - \cdots \right) \quad (4)$$

$$= (1 - s) + s \sum_{k=1}^{\infty} \alpha_k \theta^{2k} \quad (5)$$

ここで， $\alpha_k = \frac{(-1)^{k-1}}{(2k)!}$  は各 Taylor 項の符号係数である．

### 2.1.3 PolyDice-1 Loss

PolyLoss [10] は分類タスクにおいて Cross-Entropy Loss を多項式展開し，第 1 項のみを調整可能とすることで実用的な性能向上を達成した．PolyDice Loss [8] はこのアプローチを Dice Loss に適用したものであり，本研究では第 1 項のみを調整する PolyDice-1 Loss を採用する．

$$\mathcal{L}_{\text{PolyDice-1}} = (1 - s) + s \left( \frac{1}{2} + \epsilon \right) \theta^2 \quad (6)$$

ここで， $\epsilon \in \mathbb{R}$  は損失関数の形状を制御するハイパーパラメータである．Fig. 1 に， $\epsilon$  に応じた PolyDice-1 Loss の形状変化を示す． $\epsilon > 0$  では予測誤差に対するペナルティが強化され， $\epsilon < 0$  では緩和される．この柔軟な形状制御が可能な特性は，本研究の適応的学習フレームワークにおいて重要な役割を果たす．後述する提案手法では，この  $\epsilon$  を動的に調整することで，個々の画像の難易度に応じた勾配制御を実現し，学習戦略をサンプル単位で最適化することを可能にしている．




Fig. 1. Effect of the shape parameter  $\epsilon$  on PolyDice-1 Loss. The loss function is plotted as a function of  $\theta$  (the angle between prediction and ground truth vectors) with  $s = 0.1$ . Larger  $\epsilon$  values result in steeper gradients near  $\theta = 0$ , amplifying the penalty for prediction errors.



## 2.2 MC Dropout

### 2.2.1 認識的不確実性と偶然的不確実性

深層学習モデルの予測に伴う不確実性は、その発生源に基づいて偶然的不確実性と認識的不確実性に大別される [11].

偶然的不確実性 (Aleatoric Uncertainty) は、撮像装置に起因するノイズや低解像度、あるいは組織境界の物理的な曖昧さなど、データそのものに内在する情報不足に起因する。この不確実性はデータの本質的な統計的性質であるため、同一ドメインの訓練データを追加しても解消されない特性を持つ。

認識的不確実性 (Epistemic Uncertainty) は、モデルが未学習のパターンや、訓練データの不足による知識の欠如に起因する。これは適切な学習データを追加し、モデルが対象の分布をより詳細に記述することで低減が可能である。認識的不確実性が高い画像は、モデルが安定した特徴表現を獲得できておらず、予測が不安定な状態にあることを示す。本研究では、この認識的不確実性を画像のセグメンテーション難易度を反映する指標として活用する。

### 2.2.2 MC Dropout の原理と応用

Dropout は、ニューラルネットワークの過学習を防ぐ正則化手法として提案された [12]。訓練時に各層のニューロンを確率  $p$  でランダムに不活性化することで、モデルの汎化性能を向上させる。通常、推論時には Dropout は無効化され、全ニューロンが活性化された状態で決定論的な予測が行われる。

MC Dropout [9] は、学習時のみだけでなく、推論時にも Dropout を有効にすることで、モデルの認識的不確実性を推定する手法である。Dropout を有効にした状態で推論を行うと、各推論において異なるニューロンが不活性化されるため、実質的に異なる部分ネットワークによる予測が得られる。同一入力に対してこの確率的推論を複数回実行することで、予測の分布を取得できる。

Gal and Ghahramani [9] は、Dropout を適用したニューラルネットワークの学習

が、ベイズ推論における近似と数学的に等価であることを示した。この理論的枠組みにより、MC Dropout で得られる予測分布は、モデルパラメータの事後分布に基づく予測不確実性、すなわち認識的不確実性の近似として解釈できる。

提案法では、MC Dropout による推定される認識的不確実性を、画像のセグメンテーション難易度を反映する指標として活用し、損失関数の適応的制御に利用する。

### 3 提案法

#### 3.1 概要

訓練データセットを  $\mathcal{D} = \{(\mathbf{X}_n, \mathbf{Y}_n)\}_{n=1}^N$  とする．ここで， $N$  は訓練画像の総数， $\mathbf{X}_n \in \mathbb{R}^{H \times W \times C}$  は  $n$  番目の入力画像 ( $C$  はチャンネル数)， $\mathbf{Y}_n = \{y_{n,i,j}\}_{i,j} \in \mathbb{R}^{H \times W}$  は対応する正解マスクである．MC Dropout による不確実性推定では，各画像に対して  $T$  回の確率的推論を行う． $t$  回目の推論 ( $t \in \{1, \dots, T\}$ ) における予測確率マップを  $\hat{\mathbf{Y}}_n^{(t)} = \{\hat{y}_{n,i,j}^{(t)}\}_{i,j}$  と表記する．

Fig. 2 に提案手法の概要を示す．本手法の設計は，主に以下の 2 つの観点に基づいている．第一に，学習サンプルに対する難易度評価を，学習プロセスの中で動的に更新する点である．画像の難易度は絶対的なものではなく，モデルの学習進捗によって変化する相対的なものであるため，現在のモデルの状態に基づいて難易度を逐次再評価することで，その時点でのモデルにとって確信を持ってない画像に学習を集中できる．第二に，難易度の定量化指標として，認識的不確実性が適している点である．認識的不確実性は「モデルの知識不足」に起因するため，モデルが未学習のパターンや判断に迷っている領域を直接的に反映するため，ノイズに影響されることなく，学習によって改善可能な「モデルにとってどれくらい確信を持ってないか」を適切に定量化することが可能となる．

提案法では，学習中各画像に対して  $\tau$  エポックごとに MC Dropout を用いて画像毎に複数枚推論を行い，予測のばらつきから不確実性を定量化する．この不確実性情報は，モデルがその画像のセグメンテーションにおいてどの程度の確信を持ってないかを反映する．その後，この不確実性情報を画像単位に集約し，PolyDice Loss の形状を動的に制御することで，モデルが現時点で確信を持ってない画像には急峻な勾配を，既に安定した予測が可能な画像には緩やかな勾配を与える．更新された  $\epsilon$  を次の  $\tau$  エポック間の学習に適用することで，学習の進行度に応じて最適化の重み付けを動的に変化させる適応的学習を実現する．

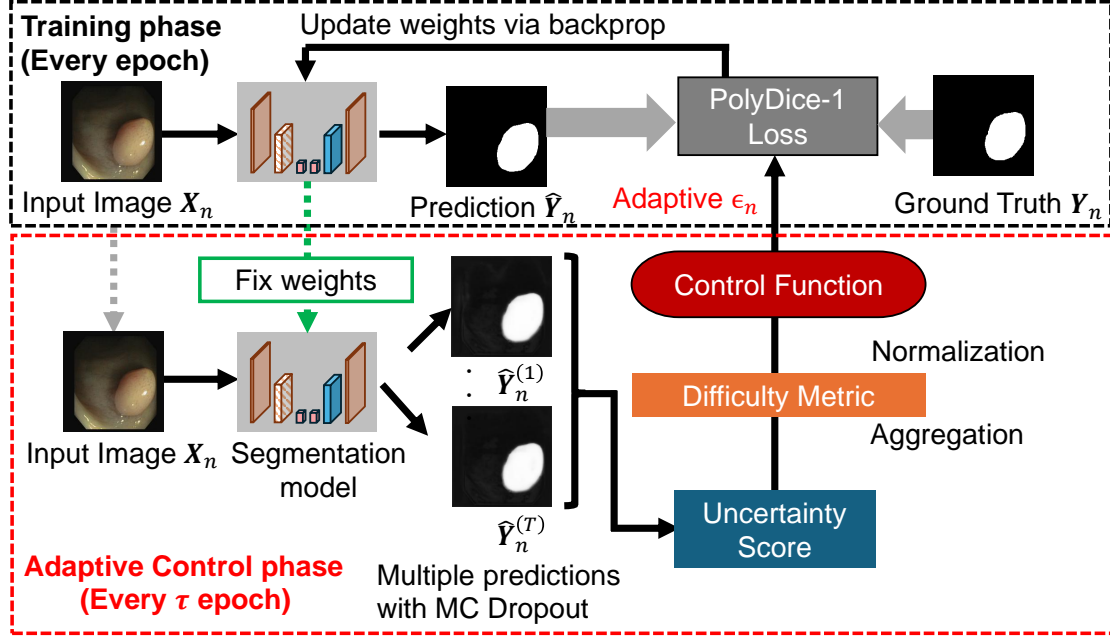


Fig. 2. Overview of the proposed adaptive learning framework. The framework alternates between (1) the adaptive control phase, executed every  $\tau$  epochs, which estimates image difficulty via MC Dropout and updates the loss shape parameter  $\epsilon$  for each sample; and (2) the training phase, which optimizes the model using sample-specific  $\epsilon$  values. This design enables dynamic gradient adjustment based on current model uncertainty.

## 3.2 不確実性に基づく画像難易度の定量化

### 3.2.1 学習中の MC Dropout 推論

提案法では、学習プロセスを初期学習期間と適応的学習期間の2段階に分割する。エポック 1 から  $E_0 - 1$  までの期間は初期学習期間とし、損失形状パラメータ  $\epsilon$  を 0 に固定して学習を行う。この期間を設ける理由は、学習初期のモデルは特徴表現が未成熟であり、この段階での不確実性は画像の本質的な難易度よりもモデルの初期化に依存するためである。 $E_0$  はモデルが基礎的なセグメンテーション能力を獲得するのに十分なエポック数として設定する。

適応的学習期間 ( $e \geq E_0$ ) においては、周期  $\tau$  ごとに不確実性の再評価と  $\epsilon$  の更新を行う。すなわち、更新は  $e \in \{E_0, E_0 + \tau, E_0 + 2\tau, \dots\}$  を満たすエポックの学習開始前に実行される。更新の際は、その時点のモデルパラメータ  $\mathbf{W}$  を固定し、訓練データの各画像  $\mathbf{X}_n$  に対して Dropout 率  $p \in (0, 1)$  で  $T$  回の確率的推論を行う。得られる予測集合を  $\{\hat{\mathbf{Y}}_n^{(t)}\}_{t=1}^T$  とする：

$$\hat{\mathbf{Y}}_n^{(t)} = f_{\mathbf{W}}(\mathbf{X}_n; \mathbf{z}^{(t)}), \quad \mathbf{z}^{(t)} \sim \text{Bernoulli}(1 - p) \quad (7)$$

ここで、 $\mathbf{z}^{(t)}$  は  $t$  回目の推論における Dropout マスクであり、 $\hat{\mathbf{Y}}_n^{(t)}$  はその予測確率マップである。この確率的推論により得られる予測のばらつきから、モデルの認識的不確実性を定量化する。

### 3.2.2 ピクセル単位の不確実性指標の計算

MC Dropout によって得られた  $T$  枚の予測画像に対し、ピクセル単位の不確実性指標として認識的不確実性を直接捉えることができる相互情報量  $I_{n,i,j}$  を計算する。

$$I_{n,i,j} = \underbrace{H\left(\frac{1}{T} \sum_{t=1}^T \hat{y}_{n,i,j}^{(t)}\right)}_{\text{Entropy of Mean}} - \underbrace{\frac{1}{T} \sum_{t=1}^T H\left(\hat{y}_{n,i,j}^{(t)}\right)}_{\text{Mean of Entropy}} \quad (8)$$

ここで、 $H(p)$  は2値分類におけるバイナリ・エントロピー関数であり、次式で定義

される。

$$H(p) = -p \log p - (1 - p) \log(1 - p) \quad (9)$$

相互情報量はモデルの予測に付随する不確実性を評価し、その依拠する要因を分離する指標として広く用いられている。  $T$  回の推論結果を平均化した後の予測分布に対する不確実性であり、データとモデルの両方に由来する不確実性を示す予測エントロピーから、個々の推論における不確実性の平均であり、データ固有のノイズや曖昧さに由来する偶然的な不確実性を示す期待エントロピーを減ずることで、認識的不確実性を定量化できる。値が高い領域はモデルが十分に学習できていないことを示唆する。

### 3.2.3 画像単位への集約

ピクセル単位の相互情報量から外れ値を除去した後の平均値を、画像全体の難易度指標として定量化する。医用画像セグメンテーションでは、背景領域が画像の大部分を占める一方で、関心領域である病変部は極めて小さいクラス不均衡が存在する。背景領域は一般に推論が容易であり、その不確実性は極めて低い値をとる傾向がある。そのため、画像全体で不確実性の平均を算出すると、大量の背景画素による低い値が難易度指標全体を支配してしまい、本来捉えるべき病変部の局所的な難易度を適切に定量化できない可能性がある。

したがって、病変検出の難易度を鋭敏に反映させるため、本手法では正解画像における病変領域に限定して相互情報量の平均を算出する。画像領域全体を  $\Omega_n$ 、正解マスクにおける陽性領域の画素集合を  $\mathcal{P}_n = \{(i, j) \in \Omega \mid y_{i,j} = 1\}$  とする。ここで、算出される相互情報量には突発的なノイズや極端な外れ値が含まれる可能性があり、これらが難易度指標の定量化を不安定にさせる要因となる。そのため、スコアの算出に先立ち、統計的な外れ値除去を行う。具体的には、領域  $\mathcal{P}_n$  内の相互情報量の平均を  $\mu_{\mathcal{P}_n}$ 、標準偏差を  $\sigma_{\mathcal{P}_n}$  とし、有効な画素集合  $\mathcal{P}'_n$  を以下のように定義する。

$$\mathcal{P}'_n = \{(i, j) \in \mathcal{P}_n \mid \mu_{\mathcal{P}_n} - 2\sigma_{\mathcal{P}_n} \leq I_{n,i,j} \leq \mu_{\mathcal{P}_n} + 2\sigma_{\mathcal{P}_n}\} \quad (10)$$

ここで、閾値として  $2\sigma_{\mathcal{P}_n}$  を採用した根拠は、統計的な信頼区間の考え方に基づく。相互情報量の分布が正規分布に近似できると仮定した場合、平均値を中心とした  $\pm 2\sigma$  の範囲内には全データの約 95% が含まれる。したがって、この範囲外のデータを棄却することで、統計的に特異な極端値（外れ値）を効果的に除去しつつ、病変部の主要な特徴を反映したロバストな難易度推定が可能となる。この有効集合  $\mathcal{P}'_n$  を用いて、画像全体の難易度スコア  $D_n$  は次式で算出される。

$$D_n = \frac{1}{|\mathcal{P}'_n|} \sum_{(i,j) \in \mathcal{P}'_n} I_{n,i,j} \quad (11)$$

ここで、 $|\mathcal{P}'_n|$  は外れ値除去後の陽性領域の画素数を表す。なお、陽性領域が存在しない画像については、 $D_n = 0$  とする。

次に、各サンプルの相対的な難易度を決定するため、データセット全体の難易度スコア分布に基づいて正規化を行う。ここでの目的は、画像毎の数値的なスケールの差異を吸収し、各画像が分布全体の中で相対的にどの程度難しいかを評価することである。データセット全体のスコア集合  $\{D_n\}_{n=1}^N$  に対し、 $q$  パーセンタイル値を  $D_q$ 、標準偏差を  $\sigma_D$  とすると、正規化されたスコアは次のように計算される。

$$D_n^{\text{norm}} = \frac{D_n - D_q}{\sigma_D + \delta} \quad (12)$$

ここで、 $\delta > 0$  は数値的安定性のための微小定数である。 $D_q$  による減算は、後述する制御関数への入力を合わせるための中心化をする役割を持つ。分布の平均値ではなく  $q$  パーセンタイル値を用いることで、容易なサンプルが多数を占める分布においても、外れ値の影響を受けずに難易度の基準点を柔軟に設定できる。 $\sigma_D$  による除算は尺度の統一であり、制御関数の感度がデータセットごとの不確実性のスケールに依存しないように調整する役割を持つ。

### 3.3 適応的損失形状制御

#### 3.3.1 制御関数の設計

得られた難易度指標  $D_n^{\text{norm}}$  に基づき, PolyDice-1 Loss の形状パラメータ  $\epsilon$  を動的に更新する. 更新式には以下のシグモイドベースの制御関数を用いる.

$$\epsilon = \epsilon_{\min} + (\epsilon_{\max} - \epsilon_{\min})\sigma(k \cdot D_n^{\text{norm}}) \quad (13)$$

ここで,  $\sigma(x) = (1 + e^{-x})^{-1}$  標準シグモイド関数,  $k > 0$  はパラメータであり,  $\epsilon_{\min}, \epsilon_{\max}$  は  $\epsilon$  の変動範囲である.

本手法でシグモイド関数を採用する理由は, 有界性と滑らかさにある. ステップ関数のような急激な切り替えは学習の安定性を損なう恐れがあり, 線形関数ではパラメータ  $\epsilon$  が適切な範囲  $[\epsilon_{\min}, \epsilon_{\max}]$  を逸脱する可能性がある. シグモイド関数を用いることで, 難易度が低い領域から高い領域への遷移を滑らかに行いつつ, 出力値を常に所定の範囲内に厳密に制約することが可能となる. パラメータ  $k$  は関数の応答感度を制御し, Fig. 3 に示すようにその値が大きいほど難易度判定の境界が急峻になり, 小さいほど滑らかな遷移となる.

この制御により, 難しい画像 ( $D_n^{\text{norm}}$  が大きい) に対しては, 大きな  $\epsilon$  を割り当て, 損失関数の勾配を急峻にする. これは, 同じ予測誤差に対してより大きな損失値と勾配を与えることを意味し, 結果として難しい画像からの学習信号が相対的に強化される. 一方, すでに十分に学習できている簡単な画像には小さな  $\epsilon$  を割り当て, 過学習を防ぎつつ学習リソースを難しい画像に集中させる. 更新された  $\epsilon$  は学習に適用され, これによりモデルは困難な画像の学習を重点的に行うことが可能となる.






Fig. 3. Sigmoid-based control function mapping normalized difficulty scores to the loss shape parameter  $\epsilon$ . The slope parameter  $k$  controls the sharpness of the transition: larger  $k$  yields a more binary assignment, while smaller  $k$  produces a gradual mapping. The function is bounded within  $[\epsilon_{\text{min}}, \epsilon_{\text{max}}]$  to ensure stable training.

### 3.3.2 学習アルゴリズム

アルゴリズム 1 に詳細なアルゴリズムを示す．学習プロセスは難易度評価と損失パラメータ更新を行う適応的制御と，実際にモデルパラメータを更新する学習段階の 2 つで構成される．

学習開始時，モデルパラメータ  $\mathbf{W}$  を初期化し，全ての画像に対する損失形状パラメータ  $\epsilon$  を 0 に初期化する． $E_0 > 0$  の場合，エポック 1 から  $E_0 - 1$  までの期間は初期学習期間とし， $\epsilon = 0$  を固定して標準的な PolyDice-1 Loss で学習を行う．この期間により，モデルは不確実性推定に必要な基礎的な特徴表現を獲得する． $E_0 = 0$  の場合は，最初のエポックから適応的制御を開始する．

適応的学習期間 ( $e \geq E_0$ ) では， $\tau$  エポックごとに適応的制御が実行される．ここでは，3.2 節で述べた手順に従い，MC Dropout 推論による不確実性指標推定，画像単位への集約，正規化を経て，各画像の  $\epsilon$  が更新される．適応的制御の段階ではモデルパラメータ  $\mathbf{W}$  は固定されており，損失関数の形状パラメータ  $\epsilon$  の更新のみが行われることに注意されたい．

続く学習段階 (Epoch  $e$ ) では，更新された  $\epsilon$  を用いてミニバッチ学習を行う．具体的には，ランダムにサンプリングされたミニバッチを構成する画像のインデックス集合を  $\mathcal{B} \subset \{1, \dots, N\}$  とする．このとき，最適化の対象となる目的関数  $\mathcal{L}$  は，バッチ内の各画像  $n \in \mathcal{B}$  に個別に割り当てられた形状パラメータ  $\epsilon_n$  を用いた PolyDice-1 Loss の平均として次式で定義される．

$$\mathcal{L} = \frac{1}{|\mathcal{B}|} \sum_{n \in \mathcal{B}} \mathcal{L}_{\text{PolyDice-1}}(\hat{\mathbf{Y}}_n, \mathbf{Y}_n; \epsilon_n) \quad (14)$$

ここで， $\mathcal{L}_{\text{PolyDice-1}}(\cdot; \epsilon_n)$  はパラメータ  $\epsilon_n$  を適用した単一画像の損失関数を表す．このように，バッチ内の各画像に対して異なる  $\epsilon_n$  を適用することで，現時点で確信を持ってない画像には急峻な勾配を，既に安定した予測が可能な画像には緩やかな勾配を同時に与えることが可能となる．最終的に，この損失関数  $\mathcal{L}$  に基づく勾配降下法によ

り，モデルパラメータ  $\mathbf{W}$  が最適化される．このサイクルを繰り返すことで，モデルの学習に応じて困難な画像の学習を重点的に行うことが可能となる．

---

**Algorithm 1** Training procedure for the proposed uncertainty-based adaptive PolyDice-1 Loss framework

---

**Require:** Training dataset  $\mathcal{D} = \{(\mathbf{X}_n, \mathbf{Y}_n)\}_{n=1}^N$ , Model  $f_{\mathbf{W}}$ , Max epochs  $E$

**Require: Hyperparameters:** Dropout probability  $p$ , Start epoch  $E_0$ , Interval  $\tau$ , MC iterations  $T$ , Normalization percentile  $q$ , Slope  $k$ , Range  $[\epsilon_{\min}, \epsilon_{\max}]$

- 1: Initialize model parameters  $\mathbf{W}$ ; set  $\epsilon_n \leftarrow 0$  for all  $n \in \{1, \dots, N\}$
- 2: **for**  $e = 1$  **to**  $E$  **do**
- 3:   **if**  $e \geq E_0$  **and**  $(e - E_0) \pmod{\tau} = 0$  **then**
- 4:     Set model to evaluation mode (enable Dropout)
- 5:     **for**  $n = 1$  **to**  $N$  **do**
- 6:       **for**  $t = 1$  **to**  $T$  **do**
- 7:          $\hat{\mathbf{Y}}^{(t)} = f_{\mathbf{W}}(\mathbf{X}_n; \mathbf{z}^{(t)})$ ,  $\mathbf{z}^{(t)} \sim \text{Bernoulli}(1 - p)$
- 8:       **end for**
- 9:       Calculate pixel-wise Mutual Information (Eq. 9):
- 10:        $I_{n,i,j} = H\left(\frac{1}{T} \sum_{t=1}^T \hat{y}_{n,i,j}^{(t)}\right) - \frac{1}{T} \sum_{t=1}^T H\left(\hat{y}_{n,i,j}^{(t)}\right)$
- 11:       **if** positive region  $\mathcal{P}_n \neq \emptyset$  **then**
- 12:         Compute  $\mu_{\mathcal{P}_n}, \sigma_{\mathcal{P}_n}$  from  $\{I_{n,i,j} \mid (i,j) \in \mathcal{P}_n\}$
- 13:         Identify valid pixels:  $\mathcal{P}'_n = \{(i,j) \in \mathcal{P}_n \mid |I_{n,i,j} - \mu_{\mathcal{P}_n}| \leq 2\sigma_{\mathcal{P}_n}\}$
- 14:          $D_n = \frac{1}{|\mathcal{P}'_n|} \sum_{(i,j) \in \mathcal{P}'_n} I_{n,i,j}$
- 15:       **else**
- 16:          $D_n \leftarrow 0$  ▷ Handle negative samples
- 17:       **end if**
- 18:     **end for**
- 19:     **Step 2: Normalization &  $\epsilon$  Update**
- 20:     Compute  $q$ -percentile  $D_q$  and std  $\sigma_D$  from  $\{D_n\}_{n=1}^N$
- 21:     **for**  $n = 1$  **to**  $N$  **do**
- 22:       Normalize score (Eq. 13):  $D_{n,\text{norm}} = \frac{D_n - D_q}{\sigma_D + \delta}$
- 23:       Update  $\epsilon_n$  (Eq. 14):  $\epsilon_n \leftarrow \epsilon_{\min} + (\epsilon_{\max} - \epsilon_{\min})\sigma(k \cdot D_{n,\text{norm}})$
- 24:     **end for**
- 25:   **else**
- 26:     ▷ Keep current  $\epsilon_n$  (Note:  $\epsilon_n = 0$  if  $e < E_0$ )
- 27:   **end if**
- 28:
- 29:   Set model to training mode (disable MC Dropout)
- 30:   **for** each minibatch  $\mathcal{B} \subset \{1, \dots, N\}$  **do**
- 31:     Compute batch loss with sample-specific  $\epsilon_n$  (Eq. 15):
- 32:      $\mathcal{L} = \frac{1}{|\mathcal{B}|} \sum_{n \in \mathcal{B}} \mathcal{L}_{\text{PolyDice-1}}(\hat{\mathbf{Y}}_n, \mathbf{Y}_n; \epsilon_n)$
- 33:     Update parameters:  $\mathbf{W} \leftarrow \mathbf{W} - \eta \nabla_{\mathbf{W}} \mathcal{L}$
- 34:   **end for**
- 35: **end for**
- 36: **return** Trained parameters  $\mathbf{W}$

---

## 4 実験

### 4.1 実験設定

#### 4.1.1 データセット

CVC-ClinicDB データセット [13] データセットおよび Kvasir-SEG データセット [14] を用いて実験を行った. CVC-ClinicDB データセットは 612 枚の大腸内視鏡画像 ( $384 \times 288$  pixel), Kvasir-SEG データセットは 1000 枚の大腸内視鏡画像で, いずれも大腸内視鏡画像とそれに対応するポリープの正解マスクから構成される. データは 5 分割交差検証で分割され, CVC-ClinicDB データセットに関しては同一のビデオシーケンスが異なる fold に跨らないよう, GroupKFold を用いた分割を行った.

#### 4.1.2 実装の詳細

セグメンテーションモデルには Table 1 に示される構造の U-Net [15] を採用した. 学習には Adam optimizer [16] を使用し, バッチサイズ 32, 学習率  $10^{-3}$  に設定した. 前処理として全画像を  $W = 224$  pixel,  $H = 224$  pixel にリサイズし, 訓練時には 50% の確率で上下左右反転および明度・コントラストの変更を適用した. 最大エポック数  $E$  は 200 に設定した.

MC Dropout による不確実評価は,  $\tau = 10$  エポックごとに実施した. Dropout 層はエンコーダの最終ブロックとデコーダの最終ブロックに配置し, 各評価時には, 先行研究 [9] を基に  $p = 0.5$  で  $T = 10$  回の確率的推論を行った. またデータセット内の難易度指標の正規化時のパーセンタイルは難易度分布の偏りを考慮して  $q = 25$  に設定し, 予備実験の結果を基に適応的学習の開始エポックは  $E_0 = 10$  とし,  $\epsilon_{\min} = 0$ ,  $\epsilon_{\max} = 0.5$ ,  $k = 2$  とした.

#### 4.1.3 比較条件

適応的学習の有効性を評価するため, 以下の手法と提案法を比較する:

- Dice Loss [4]：医用画像セグメンテーションにおける標準的な損失関数であり、ベースラインとして採用した。
- Focal Loss [17]：易しいサンプルの損失を down-weight することでクラス不均衡に対処する手法であり、提案法と「サンプルの難易度に応じた重み付け」という点で動機が共通する。ただし、Focal Loss は予測確信度に基づく静的な重み付けであるのに対し、提案法はモデルの不確実性に基づく動的な重み付けである点異なる。また易しいサンプルの損失を down-weight する割合は  $\gamma = 2$  とした。
- PolyDice-1 Loss ( $\epsilon = 0$ )：PolyDice-1 Loss の標準形式であり、理論上は通常の Dice Loss を近似したものである。提案法および後述する Optimal 設定との比較において、パラメータ  $\epsilon$  を操作すること自体の純粋な効果を検証するための基準として採用した。
- PolyDice-1 Loss (optimal)：固定  $\epsilon$  による性能の理論的上界を評価するため、テストデータに対する Dice 係数を最大化する  $\epsilon$  値を事後的に探索し、これを理想設定として比較に含めた。具体的には、 $\epsilon \in \{-0.3, -0.2, \dots, 0.5\}$  の範囲で網羅的に評価し、最高精度を達成する値  $\epsilon$  をデータセットごとに決定した。この設定は実運用では実現不可能であるが、「最適な固定値が事前に既知である」という理想的な条件下での性能を表す。

これらの比較により、(1) 提案法が標準的な損失関数より優れているか、(2) 適応的  $\epsilon$  制御が固定  $\epsilon = 0$  より有効か、(3) 提案法が Optimal 設定に匹敵あるいは上回る性能を達成できるか、を検証する。

#### 4.1.4 評価指標

またセグメンテーションの性能の評価には、領域の重なりを測る Dice 係数および IoU および検出精度を測る Precision および Recall を用いた。画像  $n$  に対するモデルの予測マップ  $\hat{Y}_n$  に対し、閾値  $\theta_{th} = 0.5$  で二値化した予測マスク  $\tilde{Y}_n = \{\tilde{y}_{n,i,j}\}$  とす

る。画像  $n$  に対する真陽性 (TP), 偽陽性 (FP), 偽陰性 (FN) の画素数はそれぞれ以下で定義される。

$$TP_n = \sum_{j=1}^W \sum_{i=1}^H \tilde{y}_{i,j} y_{i,j} \quad (15)$$

$$FP_n = \sum_{j=1}^W \sum_{i=1}^H \tilde{y}_{i,j} (1 - y_{i,j}) \quad (16)$$

$$FN_n = \sum_{j=1}^W \sum_{i=1}^H (1 - \tilde{y}_{i,j}) y_{i,j} \quad (17)$$

- Dice 係数: 正解領域と予測領域の重複度を直接評価するもので、医用画像のような不均衡な画像でも、微小な対象物の抽出精度を適切に反映できるため、主指標として採用した。

$$\text{Dice}_n = \frac{2TP_n}{2TP_n + FP_n + FN_n} \quad (18)$$

- IoU: 予測領域と正解領域の共通部分を評価する指標であり、セグメンテーションタスクにおける一般的な評価指標として広く用いられている。

$$\text{IoU}_n = \frac{TP_n}{TP_n + FP_n + FN_n} \quad (19)$$

- Precision: モデルが抽出した領域の正解率を評価する指標であり、過剰な検出を抑制する性能を定量化するために採用した。

$$\text{Precision}_n = \frac{TP_n}{TP_n + FP_n} \quad (20)$$

- Recall: 正解領域をどの程度検出できているかを評価する指標であり、特に病変の見落としを防ぐ性能を検証するために採用した。

$$\text{Recall}_n = \frac{TP_n}{TP_n + FN_n} \quad (21)$$

各指標はテストデータ全体での平均値を報告する。

Table 1. Architecture of the U-Net model used in experiments. Each layer shows the output spatial resolution and number of channels.

Layer	Output Size
— <i>Encoder</i> —	
Input	$224 \times 224 \times 3$
inc (DoubleConv)	$224 \times 224 \times 64$
down1 (MaxPool + DoubleConv)	$112 \times 112 \times 128$
down2 (MaxPool + DoubleConv)	$56 \times 56 \times 256$
down3 (MaxPool + DoubleConv)	$28 \times 28 \times 512$
down4 (MaxPool + DoubleConv)	$14 \times 14 \times 512$
— <i>Decoder</i> —	
up1 (Upsample + DoubleConv)	$28 \times 28 \times 256$
up2 (Upsample + DoubleConv)	$56 \times 56 \times 128$
up3 (Upsample + DoubleConv)	$112 \times 112 \times 64$
up4 (Upsample + DoubleConv)	$224 \times 224 \times 64$
outc (Conv2d)	$224 \times 224 \times 2$



## 4.2 結果と議論

### 4.2.1 比較手法との性能比較

Table 2 および Table 3 に、各データセットにおける比較手法との性能比較を示す。両データセットにおいて、提案法は全ての比較手法を上回る性能を達成した。Focal Loss は両データセットにおいて Dice Loss を下回る結果となった。特に注目すべきは、テストデータに対して最適な固定  $\epsilon$  を事後探索した PolyDice-1 Loss (optimal) をも上回った点である (Fig. 4)。固定  $\epsilon$  では全画像に同一の勾配特性が適用されるため、容易な画像への過学習と困難な画像の学習不足が同時に生じうる。さらに、学習進行に伴い各画像の相対的な難易度は変化するが、固定  $\epsilon$  ではこの変化に追従できない。提案法は  $\tau$  エポックごとに難易度を再評価し、 $\epsilon$  を動的に更新することで、これらの問題を回避している。

なお、Focal Loss は容易なサンプルの損失を低減することでクラス不均衡に対処する手法であるが、セグメンテーションタスクでは画像単位ではなくピクセル単位で生じる。そのため、ピクセルの予測不確実性のみに基づく重み付では、画像全体としてのセグメンテーション難易度を適切に反映できなかったと考えられる。

### 4.2.2 難易度別の性能分析

提案手法の設計意図である「困難な症例に対しては急峻な勾配を与え、容易な症例に対しては緩やかな勾配を与える」という適応的学習戦略の有効性を検証するため、症例の難易度に基づいた層別分析を行った。難易度の分類には、提案法とは独立した基準として、ベースラインである Dice Loss で学習したモデルのテストデータに対する Dice 係数を用いた。具体的には、Dice 係数が下位 33 パーセンタイル未満の症例を「困難 (Hard)」, 33 パーセンタイル以上 66 パーセンタイル未満を「中程度 (Medium)」, 66 パーセンタイル以上を「容易 (Easy)」と定義した。

Fig. 5 に、両データセットにおける各難易度層別の性能比較を示す。Hard 症例群において、提案法はベースラインである Dice Loss と比較して Dice 係数が CVC-

ClinicDB で 0.32, Kvasir-SEG で 0.13 向上した。これは、不確実性が高く困難と判定された症例に対して大きな  $\epsilon$  を割り当て、損失関数の勾配を急峻にしたことで、モデルがこれらの画像の特徴を重点的に学習できたことを示唆している。一方、Easy および Medium 症例群においては、精度変化が小さく一部でわずかな低下も見られた。この結果は、十分に学習が進んだ症例からの勾配を相対的に抑制するという設計意図を反映しており、容易なパターンへの過学習を防いだ結果と解釈できる。以上の結果から、提案法による全体性能の向上は、主として困難な症例における大幅な改善に起因することが確認された。

#### 4.2.3 適応的制御のメカニズム分析

提案手法の動作メカニズムを理解するため、訓練データに対するパラメータ  $\epsilon$  の推移を難易度別に分析した。Fig. 6 に、CVC-ClinicDB データセットにおける各難易度層別の  $\epsilon$  の推移を示す。分析の結果、各群の  $\epsilon$  の分布には明確な分離が見られなかった。特に注目すべきは学習初期（10–40 エポック付近）の挙動であり、最終的に Easy と分類される画像群の  $\epsilon$  が、Hard 群よりも高い値を示す傾向が観察された。

この一見矛盾する結果は、難易度分類と  $\epsilon$  算出の基準の違いに起因すると解釈できる。本研究における難易度分類は、Dice Loss を用いたベースラインモデルの学習完了後の最終精度に基づく事後的な指標である。一方、 $\epsilon$  は各時点におけるモデルの不確実性から動的に算出される。この定義の乖離が学習段階に応じて各群の  $\epsilon$  が異なる挙動を示したと考えられる。

具体的には、学習初期において Easy 症例群の画像はモデルにとって未学習の状態であるため、予測のばらつきが大きく、算出される不確実性が一時的に高くなる。一方、Hard 群の画像に対しては、モデルがその複雑さを認識できるほどの特徴抽出能力をまだ獲得しておらず、誤った領域を高い確信度で予測する過信（Overconfidence）が生じる。その結果、Hard 群に対する不確実性が過小評価され、 $\epsilon$  が相対的に低く抑えられたと考えられる。学習の進行に伴い、Easy 症例群は、速やかに安定した特徴表現を獲得し、予測のばらつきが収束するため、 $\epsilon$  は急速に低下する。これに対し、Hard 群で

はモデルが徐々に症例の複雑さを認識し始め、不確実性が適切に上昇することで  $\epsilon$  の値が上昇に転じる。

以上の分析から、提案法が静的な難易度ラベルに基づく重み付けではなく、モデルの現在の学習状態に応じた動的な勾配調整として機能していることが示唆される。すなわち、「困難な画像に大きな勾配を与える」というよりも、「既に学習が完了した画像の勾配を抑制し、未学習の画像への学習を促進する」メカニズムとして解釈できる。この動的な適応制御が、結果として困難な症例の学習促進に寄与していると考えられる。

続いて、 $\epsilon$  の動的制御が学習過程に与える影響を検証するため、訓練データに対する Dice 係数の推移を難易度群別に分析した。Fig. 7 に結果を示す。Easy 群および Medium 群では、提案法とベースラインの間に顕著な差は見られず、両手法ともに学習初期から急速に高精度へ収束した。一方、Hard 群では提案法がベースラインを一貫して上回り、学習後期においてその差がさらに拡大する傾向が観察された。

この結果は、Fig. 6 で示した  $\epsilon$  の推移と整合的である。学習初期において Easy 群の  $\epsilon$  が一時的に高くなることで学習が促進され、その後  $\epsilon$  が低下することで過学習が抑制される。一方、Hard 群では  $\epsilon$  が学習の進行とともに上昇し、継続的な学習信号の強化が行われる。この動的な勾配調整により、結果として困難な症例の学習が促進されたと考えられる。




Fig. 4. Comparison of segmentation performance (Dice coefficient) between the proposed adaptive method and PolyDice-1 Loss with various fixed  $\epsilon$  values. The left graph shows the results for the CVC-ClinicDB dataset, and the right graph shows the results for the Kvasir-SEG dataset. The red dashed line represents the performance of the proposed method, demonstrating robustness comparable to or exceeding the optimal fixed parameter settings.

Table 2. Performance Comparison with Existing Loss Functions on CVC-ClinicDB Dataset

Method	Dice	IoU	Precision	Recall
Dice Loss	0.5408	0.4347	0.6359	0.5819
Focal Loss ( $\gamma = 2$ )	0.5007	0.4133	0.7078	0.4707
PolyDice-1 ( $\epsilon = 0$ )	0.5825	0.4808	0.6817	0.6167
PolyDice-1 (Opt. $\epsilon$ )	0.6145	0.5145	0.7090	0.6372
Adaptive PolyDice-1	<b>0.6924</b>	<b>0.5262</b>	<b>0.7827</b>	<b>0.7113</b>

Table 3. Performance Comparison with Existing Loss Functions on Kvasir-SEG Dataset

Method	Dice	IoU	Precision	Recall
Dice Loss	0.7895	0.7021	0.8281	0.8154
Focal Loss ( $\gamma = 2$ )	0.7192	0.6082	0.8634	0.6769
PolyDice-1 ( $\epsilon = 0$ )	0.8095	0.7198	0.8461	0.8268
PolyDice-1 (Opt. $\epsilon$ )	0.8095	0.7198	0.8461	0.8268
Adaptive PolyDice-1	<b>0.8272</b>	<b>0.7440</b>	<b>0.8707</b>	<b>0.8397</b>

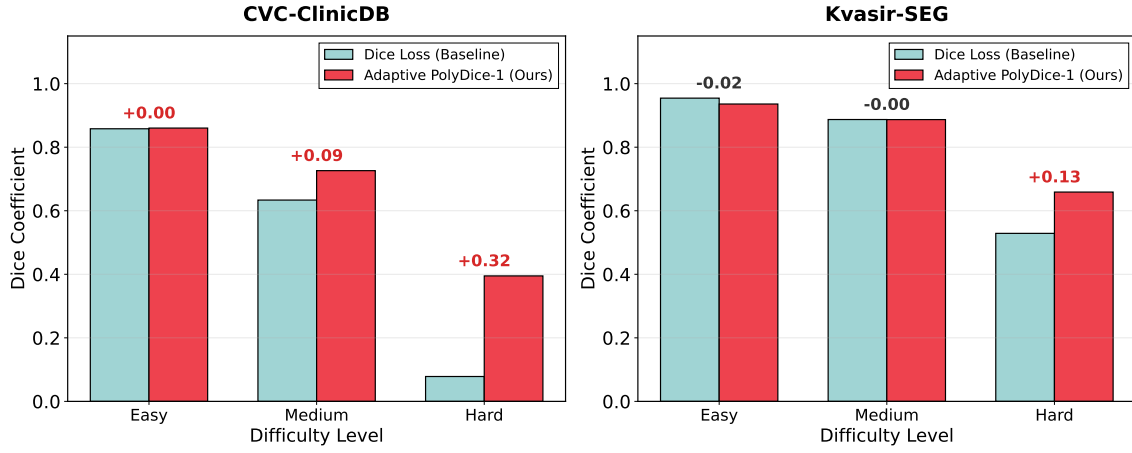


Fig. 5. Stratified performance comparison of the Dice coefficient across three difficulty levels (Easy, Medium, Hard) on the CVC-ClinicDB (left) and Kvasir-SEG (right) datasets. The proposed Adaptive PolyDice-1 Loss (red bars) demonstrates consistent improvements over the baseline Dice Loss (blue bars), particularly in the “Hard” category, where significant performance gains (+0.32 and +0.13) are observed.




Fig. 6. Evolution of the adaptive parameter  $\epsilon$  throughout the training process on the CVC-ClinicDB dataset. Cases are categorized into “Easy,” “Medium,” and “Hard” based on their baseline segmentation performance. Solid lines represent the mean values, and shaded regions denote the 99% confidence intervals.




Fig. 7. Dice coefficient transitions throughout training for different difficulty levels on CVC-ClinicDB. Curves show the mean values of the proposed (red) and baseline (gray) methods, with shaded areas indicating 99% confidence intervals.



#### 4.2.4 ハイパーパラメータの影響

本節では、提案法における主要なハイパーパラメータの感度分析を行い、設計選択の妥当性を検証する。

**$\epsilon$  範囲の影響：**Table 4 および Table 5 に示すように、 $\epsilon$  の変動範囲を  $[0, 0.5]$  と設定した場合に、両データセットにおいて最も良好なセグメンテーション性能が得られた。上限値  $\epsilon_{\max}$  を 0.3 から 0.5 へ拡大したことで、困難な症例に対してより大きな  $\epsilon$  を割り当て可能となり、損失関数の勾配が適切に強調され、病変特徴の学習が促進されたと考えられる。一方、下限値  $\epsilon_{\min}$  を  $-0.3$  まで拡張した設定 ( $\epsilon_{\min} = -0.3, \epsilon_{\max} = 0.5$ ) では、 $\epsilon_{\min} = 0$  の場合と比較して性能が向上しなかった。これは、変動範囲の過度な拡大により不確実性推定に含まれる微細なノイズに対する感度が必要以上に高まり、学習の安定性を損なったためと考えられる。

**感度パラメータ  $k$  の影響：**Table 6 および Table 7 に、難易度スコアに対するシグモイド関数の傾き  $k$  を変化させた結果を示す。Kvasir-SEG データセットでは  $k = 2$  の場合に最も精度が高く、CVC-ClinicDB では  $k = 3$  がわずかに高い値を示したものの、 $k = 2$  も同等の性能を達成した。 $k = 1$  のように傾きが緩やかすぎる場合、難易度の差が損失形状に十分に反映されない。逆に  $k = 3$  のように急峻すぎる場合、損失形状が二値的に切り替わり、学習が不安定になる可能性がある。以上より、 $k = 2$  が難易度に応じた滑らかな適応と安定した学習の両立において適切な設定であると考えられる。

**適応開始エポック  $E_0$  の影響：**Fig. 8 に示すように、適応的学習の開始タイミングは早いほど良好な結果をもたらし、最も早い  $E_0 = 10$  において最高性能を記録した。4.2.3 で示したように、学習初期の段階で既に症例間の学習進捗に明確な差異が生じており (Fig. 7 参照)、この段階から適応的制御を開始することで、未学習の症例への学習促進効果を最大化できたと考えられる。

Table 4. Impact of the adaptive  $\epsilon$  range  $[\epsilon_{\min}, \epsilon_{\max}]$  on segmentation performance (CVC-ClinicDB dataset).

$\epsilon_{\min}$	$\epsilon_{\max}$	Dice	IoU	Precision	Recall
0	0.3	<b>0.7017</b>	<b>0.6050</b>	<b>0.7875</b>	<b>0.7234</b>
0	0.5	0.6924	0.5913	0.7827	0.7113
-0.3	0.5	0.7000	0.5993	0.7818	0.7220

Table 5. Impact of the adaptive  $\epsilon$  range  $[\epsilon_{\min}, \epsilon_{\max}]$  on segmentation performance (Kvasir-SEG dataset).

$\epsilon_{\min}$	$\epsilon_{\max}$	Dice	IoU	Precision	Recall
0	0.3	0.8239	0.7391	0.8608	0.8410
0	0.5	<b>0.8272</b>	<b>0.7440</b>	<b>0.8707</b>	0.8397
-0.3	0.5	0.8189	0.7313	0.8537	<b>0.8454</b>

Table 6. Sensitivity analysis of the sigmoid slope parameter  $k$  in the control function (CVC-ClinicDB dataset).

$k$	Dice	IoU	Precision	Recall
1	0.6935	0.5962	0.7853	0.7175
2	0.6924	0.5913	0.7827	0.7113
3	<b>0.7063</b>	<b>0.6084</b>	<b>0.8010</b>	<b>0.7178</b>

Table 7. Sensitivity analysis of the sigmoid slope parameter  $k$  in the control function (Kvasir-SEG dataset).

$k$	Dice	IoU	Precision	Recall
1	0.8235	0.7404	0.8589	<b>0.8440</b>
2	<b>0.8272</b>	<b>0.7440</b>	<b>0.8707</b>	0.8397
3	0.8229	0.7375	0.8663	0.8370




Fig. 8. Effect of adaptation start epoch  $E_0$  on segmentation performance (Dice coefficient) for the CVC-ClinicDB (left) and Kvasir-SEG (right) datasets.

#### 4.2.5 定性的評価

Fig. 9 に、CVC-ClinicDB データセットにおける各難易度層の代表的な症例について、比較手法と提案法のセグメンテーション結果を示す。境界が明瞭な容易な症例および中程度の症例においては、既存手法と提案法の両方が高精度なセグメンテーションを実現している。一方、ポリープと粘膜壁のコントラストが低く境界が不明瞭な困難な症例において、ベースラインである Dice Loss や Focal Loss ではポリープ領域を捉えきれず、著しい過少検出が発生した。PolyDice-1 Loss (optimal) においても検出が不完全である。これに対し、提案法はポリープ境界を適切に捉えており、良好なセグメンテーション結果を達成している。この結果は、提案法が MC Dropout により当該症例を困難な画像と判定し、損失関数の形状パラメータ  $\epsilon$  を大きく設定したことで、学習時に勾配が強化され、低コントラスト領域における特徴抽出能力が向上したことを示唆している。

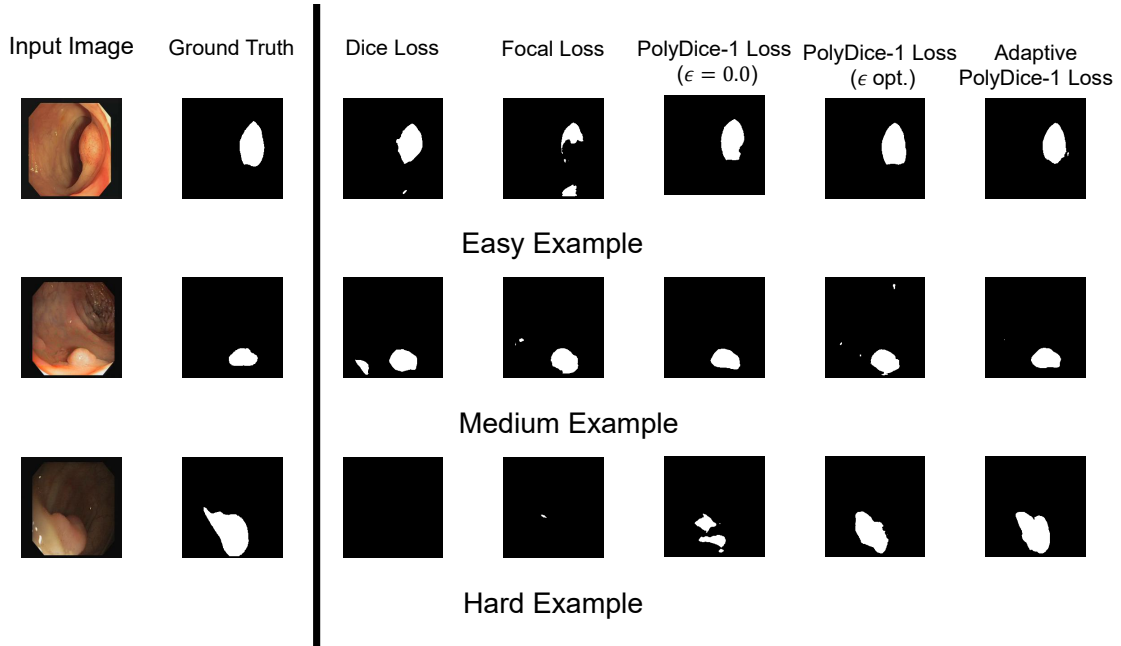


Fig. 9. Qualitative comparison of segmentation results on the CVC-ClinicDB dataset. Each row represents a different difficulty level (easy, medium, hard), categorized by baseline Dice Loss performance.

## 5 結論

本稿では、医用画像セグメンテーションにおける適応的学習手法を提案した。提案法では、MC Dropout を用いてモデルの認識的不確実性を定量化し、これを画像のセグメンテーション難易度の指標として活用する。得られた難易度指標に基づき、PolyDice-1 Loss の形状パラメータを動的に制御することで、モデルの学習状態に応じた適応的な勾配調整を実現した。この動的制御により、結果として困難な症例の学習が促進されることを確認した。

CVC-ClinicDB および Kvasir-SEG データセットを用いた評価実験において、提案法は Dice Loss や FocalLoss などの既存手法に加え、テストデータに対して最適化された固定パラメータ設定をも上回る性能を達成した。特に、従来手法では抽出が困難であった症例群に対して、CVC-ClinicDB において Dice 係数が 0.32 向上するなど、提案する適応的学習戦略が困難な病変の検出に有効であることが示された。

本手法の限界として、不確実性推定のために複数回の推論を要するため、標準的な学習と比較して計算コストが増加する点が挙げられる。また、現在の枠組みは経験的に設定されたハイパーパラメータに依存しており、これらをデータセットに応じて自動最適化する手法の確立が課題として残されている。今後は、計算効率の改善に取り組むとともに、CT や MRI などの 3 次元医用画像へ本手法を拡張し、より広範な臨床タスクにおける有効性を検証する予定である。

## 謝辞

本研究を遂行するにあたり、終始熱心なご指導と多大なるご鞭撻を賜りました、指導教員の古居彬准教授に心より感謝申し上げます。古居准教授には、研究の方向性に関する議論から、論文執筆、プレゼンテーション技術に至るまで、細部にわたり丁寧にご指導いただきました。配属当初は期待と不安が入り混じっておりましたが、先生の時に親身で、時に厳格なご助言のおかげで、迷うことなく研究に邁進することができました。

副指導教員として中間発表でアドバイスしてくださった向谷博明教授、曾智准教授に厚く御礼申し上げます。先生方から頂いた鋭いご指摘は、本研究の質を高め、議論を深める上で極めて重要な指針となりました。

また、共同研究において多角的な視点から貴重なご意見をいただきました相澤宏旭助教に深く感謝致します。学部時代の講義で得た基礎知識が、最先端の研究課題といかに結びつくかをご教示いただき、学問の奥深さと面白さを改めて実感する得難い機会を与えてくださいました。

日々の研究生活において、知能生体情報学研究室の皆様の存在は、私にとって大きな心の支えでした。全体ゼミでの活発な議論はもとより、研究の合間に食事を共にし、日々の他愛もない会話で笑い合った時間は、私にとってかけがえのない思い出です。

最後に、私の大学院進学を快く認め、在学期間中、経済的・精神的に支え続けてくれた両親に、心からの感謝を捧げます。何不自由なく研究に打ち込める恵まれた環境は、家族の献身的な支えがあったからこそ実現したものです。

ここに記して、深甚なる感謝の意を表します。

## 参考文献

- [1] G.-P. Ji, G. Xiao, Y.-C. Chou, D.-P. Fan, K. Zhao, G. Chen, and L. Van Gool, “Video polyp segmentation: A deep learning perspective,” *Machine Intelligence Research*, vol. 19, no. 6, pp. 531–549, 2022.
- [2] F. Maleki, W. T. Le, T. Sananmuang, S. Kadoury, and R. Forghani, “Machine learning applications for head and neck imaging,” *Neuroimaging Clinics*, vol. 30, no. 4, pp. 517–529, 2020.
- [3] J. Long, E. Shelhamer, and T. Darrell, “Fully convolutional networks for semantic segmentation,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 3431–3440, 2015.
- [4] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” in *2016 Fourth International Conference on 3D Vision (3DV)*, pp. 565–571. IEEE, 2016.
- [5] W. Zhu, Y. Huang, L. Zeng, X. Chen, Y. Liu, Z. Qian, N. Du, W. Fan, and X. Xie, “AnatomyNet: deep learning for fast and fully automated whole-volume segmentation of head and neck anatomy,” *Medical Physics*, vol. 46, no. 2, pp. 576–589, 2019.
- [6] G. Wang, X. Liu, C. Li, Z. Xu, J. Ruan, H. Zhu, T. Meng, K. Li, N. Huang, and S. Zhang, “A noise-robust framework for automatic segmentation of COVID-19 pneumonia lesions from ct images,” *IEEE Transactions on Medical Imaging*, vol. 39, no. 8, pp. 2653–2663, 2020.
- [7] S. Kato and K. Hotta, “Adaptive t-vMF dice loss: An effective expansion of dice loss for medical image segmentation,” *Computers in Biology and Medicine*, vol. 168, pp. 107695, 2024.
- [8] H. Aizawa, “Polynomial dice loss for medical image segmentation,” (submit-



ted).

- [9] Y. Gal and Z. Ghahramani, “Dropout as a Bayesian approximation: Representing model uncertainty in deep learning,” in *Proceedings of the 33rd International Conference on Machine Learning*, vol. 48, pp. 1050–1059, 20–22 Jun 2016.
- [10] Z. Leng, M. Tan, C. Liu, E. D. Cubuk, J. Shi, S. Cheng, and D. Anguelov, “Polyloss: A polynomial expansion perspective of classification loss functions,” in *International Conference on Learning Representations*, 2022.
- [11] L. Smith and Y. Gal, “Understanding measures of uncertainty for adversarial example detection,” *arXiv preprint arXiv:1803.08533*, 2018.
- [12] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 56, pp. 1929–1958, 2014.
- [13] J. Bernal, F. J. Sánchez, G. Fernández-Esparrach, D. Gil, C. Rodríguez, and F. Vilariño, “WM-DOVA maps for accurate polyp highlighting in colonoscopy: Validation vs. saliency maps from physicians,” *Computerized Medical Imaging and Graphics*, vol. 43, pp. 99–111, 2015.
- [14] D. Jha, P. H. Smedsrud, M. A. Riegler, P. Halvorsen, T. d. Lange, D. Johansen, and H. D. Johansen, “Kvasir-SEG: A segmented polyp dataset,” in *Proceedings of the 26th International Conference on Multimedia Modeling (MMM 2020), Part II*, vol. 11962 of *Lecture Notes in Computer Science*, pp. 451–462, Springer. 2020.
- [15] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pp. 234–241. Springer, 2015.

- [16] D. P. Kingma and J. Ba, “Adam: A method for stochastic optimization,” in *Proceedings of the 3rd International Conference on Learning Representations (ICLR)*, 2015.
- [17] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision*, pp. 2980–2988, 2017.